

機械学習 Classification

最も単純な 2 クラス分類

rkskmt

1

分類問題

目標

- 分類問題(Data Classification)：データを分類するタスクを理解する
→ 2クラス分類
- データ可視化
- **決定境界 (decision boundary)** の概念を学ぶ

① ここがポイント

- 完全な分類は困難であることを知る
- 境界決定のトレードオフとコスト

2

今回の問題

サケだけを選別せよ

- 魚はベルトコンベアで大量に流れてくる
→ 時間をかけず選別したい
- サケ以外の魚も混じっている
→ 一旦、**サケ** (Salmon) か **スズキ** (Sea bass) か
→ 分類項目を **クラス (class)** という





① ここがポイント

Salmon と Sea bass の **2クラス識別(2-class classification)** 問題

3

選別システム



4

試行1: 重さだけで分類してみる

アプローチ

- 重量計をつけられそうなので、まず重さで識別できないかを考えた
- まずサンプルとして20匹ずつの重さを測定した

Code

```
1 # Salmon (20匹) の重さ (g)
2 salmon_weights = [2149, 1959, 2194, 2457, 1930, 1930, 2474, 2230, 1859, 2163,
3                   1861, 1860, 2073, 1426, 1483, 1831, 1696, 2094, 1728, 1576]
4
5
6 # Sea bass (20匹) の重さ (g)
7 seabass_weights = [1677, 1327, 1486, 1440, 1857, 1476, 1749, 2203, 1979, 1468,
8                   1496, 1737, 1099, 1341, 1748, 1563, 2181, 1414, 1286, 1333]
```

5

準備

pandas, numpy, matplotlib, scikit-learn をインストールする。

```
1 pip install pandas numpy matplotlib scikit-learn
```

続けて、以下を実行

▶ 全体を表示

6

まずはヒストグラム

▶ code

7

統計値を見る

▶ code

⚠ 発見

- **双峰型の分布**：2つの山が見える
→ **重なっている** が、まあ分けられそう？

8

境界線（閾値）を考える

大体でいいので **しきい値（threshold）** を設定する。

方針

1800g以上 → Salmon **1800g未満** → Sea bass

この判定ルールで分類してみる。

9

青破線で切ったとしたら

10

分類結果：4つのパターン

境界線1800gで分類すると、4つのパターンが生まれる：


実際の魚	判定結果	略称	説明
Salmon	Salmon	TP (True Positive)	正しく Salmonと判定
Sea bass	Sea bass	TN (True Negative)	正しく Salmonでは ない と判定
Sea bass	Salmon	FP (False Positive)	誤って Salmonと判定
Salmon	Sea bass	FN (False Negative)	Salmonを 見逃し

11

TP/FP/TN/FNの覚え方

右から左に読む

- 1. 右 (P/N) 判定結果 → Positive (サケ) or Negative (それ以外)
- 2. 左 (T/F) その答え合わせ → True (正解) or False (不正解)



12

混同行列 (Confusion Matrix)

▶ code

13

判定器の評価

▶ code

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{\text{全体}} = \frac{\text{正しく分類できた数}}{\text{全データ数}} \\ \text{Precision} &= \frac{TP}{TP + FP} = \frac{\text{正しいSalmon判定}}{\text{Salmonと判定した全て}} \\ \text{Recall} &= \frac{TP}{TP + FN} = \frac{\text{検出できたSalmon}}{\text{実際のSalmon全て}} \end{aligned}$$

14

しきい値を変えると？

▶ code

❗ 重要

- **境界を下げる（1600g）** → Recall ↑、Precision ↓
→ Salmonを逃さない（FN減）が、Sea bassの誤判定（FP増）
- **境界を上げる（2000g）** → Precision ↑、Recall ↓
→ Salmon判定の信頼性は高いが、Salmonを見逃す（FN増）

Precision と Recall はトレードオフの関係

15

しきい値の比較（1600g vs 2000g）

- FP= `{python} FP`
- FN= `{python} FN`
- **Precision:** `{python} f" {precision:.1%}"` (低い)
- **Recall:** `{python} f" {recall:.1%}"` (高い)

FP= `{python} FP` , FN= `{python} FN`

Precision: `{python} f" {precision:.1%}"` (高い)

Recall: `{python} f" {recall:.1%}"` (低い)

16

どの指標を重視すべきか？

ケース1: 高級レストラン向け出荷

- **Precision重視**（FPを避ける）
- Sea bassの混入を最小化。混入絶対許さないマン
- → 高めの閾値（2000g）

ケース2: 缶詰工場（Salmon専用ライン）

- **Recall重視**（FNを避ける）
- Salmonの取りこぼしを最小化。シャケ全部入れるマン
- → 低めの閾値（1600g）

17

コストを考慮した最適化

誤分類のコストが異なる場合、総コストを最小化するしきい値を選ぶ。

$$\text{argmin}(\text{総コスト}) = N(\text{FP}) \times \text{Cost}(\text{FP}) + N(\text{FN}) \times \text{Cost}(\text{FN})$$

$N(x)$: x の個数, $\text{Cost}(x)$: x 1個あたりのコスト

▶ code

このコスト関数での最適なしきい値: 2000g (総コスト最小)



Tweak

しきい値を振り回す

- 混同行列のコード の **threshold** と、コスト最適化のコード を書き換えて実行 (指標のセルまで続けて実行)

1	全部 Salmon と言い張る	threshold = 1000
2	全部 Sea bass と言い張る	threshold = 2500
3	再選別のほうが高くつく世界	C_FP = 500、C_FN = 10000

💡 ここで観察

- **threshold = 1000** で **Recall は 100%** になる — 全部 Salmon と言えばタダで手に入る数字 (そのとき Precision は 50%、Accuracy も 50%)。 **単独の指標は当てにならない**
- コストを入れ替えると、最適しきい値が **2000g から 1600g に反転** する — 「境界線は方針の選択」が数字で見える

試行1の結論

❗ 重要なポイント

1. **重さだけでは完全な分類は不可能**
→ データの分布が重なっている
2. **境界線は「方針の選択」**
→ 正解/不正解ではなく、用途に応じた最適化 (optimization)
3. **評価指標はトレードオフ**
→ Precision ↑ → Recall ↓
→ どちらを重視するかは用途次第

練習問題

下記のデータ（それぞれ20匹ずつ追加した）について、以下の0～4を実行して分類器をつくれ。

Code

```
1 salmon_weights = [2149, 1959, 2194, 2457, 1930, 1930, 2474, 2230, 1859, 2163,
2                   1861, 1860, 2073, 1426, 1483, 1831, 1696, 2094, 1728, 1576,
3                   2028, 1903, 2057, 1629, 1884, 1884, 2240, 2081, 1838, 2037,
4                   1839, 1738, 1978, 1754, 1991, 1720, 1731, 1992, 1752, 1652]
5 seabass_weights = [1677, 1327, 1486, 1440, 1857, 1476, 1749, 2203, 1979, 1468,
6                   2015, 1528, 1612, 1183, 1436, 1625, 1261, 1701, 1420, 1509,
7                   1387, 1345, 1505, 1204, 1381, 1513, 1259, 1567, 1370, 1432,
8                   1370, 1864, 1488, 1278, 1657, 1245, 1533, 1096, 1223, 1531]
```

以下をレポートで提出

- 0. まず何をするべきかを考えて実行せよ。
- 1. 閾値を1800gにした場合の TP, FP, FN, TN を計算せよ
- 2. 1800gの場合の **Accuracy, Precision, Recall** を求めよ。
- 3. 1700gの場合の **Accuracy, Precision, Recall** を求めよ。
- 4. $C_{FP} = 5000$ 円、 $C_{FN} = 1000$ 円としたとき、総コストを最小にするしきい値を求めよ

問0の答え